

# UNIVERSIDAD DE GRANADA

# BIG DATA I MÁSTER CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES

# CLOUD COMPUTING Y BIG DATA

# PRÁCTICA SOBRE CONTENEDORES

# Autor

Ignacio Vellido Expósito ignaciove@correo.ugr.es





ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

 $Curso\ 2020\hbox{-}2021$ 

# $\mathbf{\acute{I}ndice}$

1.	Con	tenedor para actividades de ciencia de datos basado en R	2
	1.1.	Descripción	2
	1.2.	Archivo Dockerfile	2
	1.3.	Proceso de construcción	:
		1.3.1. En hadoop.ugr.es	:
		1.3.2. En Azure	4
	1.4.	Evaluación	7
2.	Con	tenedor para actividades de ciencia de datos basado en Python	ę
	2.1.	Descripción	Ć
	2.2.	Archivo Dockerfile	Ć
	2.3.	Proceso de construcción	1(
		2.3.1. En hadoop.ugr.es	1(
		2.3.2. En Azure	12
	2.4.	Evaluación	14
3.	Con	tenedor con SGDB MySQL	15
	3.1.	Descripción	15
	3.2.	Archivo Dockerfile	15
	3.3.	Proceso de construcción	15
		3.3.1. En local	15
		3.3.2. En Azure	
	3.4.	Evaluación	2(

# 1. Contenedor para actividades de ciencia de datos basado en R

# 1.1. Descripción

Contenedor partiendo de una imagen base de Ubuntu al que se le añade R con distintos paquetes de ciencia de datos, concretamente:

- tidyverse
- caret
- RSNNS
- frbs
- FSinR
- forecast

# 1.2. Archivo Dockerfile

```
1 FROM ubuntu
2 LABEL author="Ignacio Vellido Expósito"
3 ENV http_proxy http://stargate.ugr.es:3128
4
5 # To don't get asked about geographic location (disable dpkg interactivity)
6 ENV DEBIAN_FRONTEND=noninteractive
7
8 # Install R and tidyverse
9 RUN apt-get update && \
10 apt-get install -y r-base \
11 | r-cran-tidyverse
12
13 RUN R -e "install.packages(c('caret','RSNNS','frbs','FSinR','forecast'), \
14 dependencies=TRUE, repos='http://cran.rstudio.com/')"
15 |
16 # Launch test script
17 COPY testDocker.R /home/testDocker.R
18 RUN cd /home && \
19 Rscript /home/testDocker.R > /home/testOutput.txt
20 |
21 # Launch R
22 CMD [ "R" ]
```

Figura 1

El paquete "tidyverse" es necesario instalarlo a través de apt-get para evitar errores. Se incluye el proceso de testeo dentro del dockerfile para agilizar las pruebas, y se concluye indicando el comando por defecto de ejecución del script.

# 1.3. Proceso de construcción

# 1.3.1. En hadoop.ugr.es

```
Concline makes an attract/coff decice build a x 97965160/cof .

Step 19 : RMM ubunt

- 766427526252

Step 29 : LABEL a thor-Zignacio Vellido Expósito*

Step 39 : EMBL a thor-Zignacio Vellido Expósito*

Step 30 : EMBL a thor-Zignacio Vellido Expósito

Step 30 : EMBL a thor
```

Figura 2: Construcción de la imagen.

```
x79056166@hadoop-master:~/cdr$ docker run -i -t x79056166/cdr
R version 3.6.3 (2020-02-29) -- "Holding the Windsock"
Copyright (C) 2020 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)
R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.
Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.
```

Figura 3: Lanzando la imagen.

```
ter:~/cdr$ docker run -i -t x79056166/cdr /bin/bash
root@5ace4be08114:/# ls /home/
Rplots.pdf testDocker.R test(
                                gplot.png testOutput.txt
root@5ace4be08114:/# cat /home/testOutput.txt
c-Nearest Neighbors
150 samples
 4 predictor
 2 classes: 'negative', 'positive'
Pre-processing: centered (4), scaled (4)
Resampling: Cross-Validated (5 fold, repeated 3 times)
Summary of sample sizes: 120, 120, 120, 120, 120, 120, ...
Resampling results across tuning parameters:
                 Sens
                            Spec
     0.9400000
                 0.9600000
                            0.9200000
     0.9701667
                 0.9666667
                            0.9266667
     0.9895000
                 0.9766667
                            0.9400000
                            0.9066667
     0.9923333
                 0.9766667
     0.9918333
                 0.9800000
                            0.9066667
     0.9908333
                 0.9733333
                            0.9133333
ROC was used to select the optimal model using the largest value.
The final value used for the model was k = 7.
```

Figura 4: Contenido de la imagen.

x79056166@hadoop-master:-\$ 1s	x79056166@hadoop-master:∿\$ docker ps CONTAINER ID IMAGE	COMMAND	CREATED	STATUS	PORTS
56166@hadoop-master: <b>~\$ cd cdpython/</b>  56166@hadoop-master: <b>~/cdpython\$ ls</b>	NAMES 60853475d0d7 x79056166/cdr		24 seconds ago	Up 22 seconds	
Dockerfile requirements.txt testDocker.py x79056166@hadoop-master: <b>~/cdpython\$ docker run -i -t x79056166/cdr</b>	angry_vaughan d72f5ec0f688 nginx 0/tcp quirky beaver	"/docker-entrypoint"	22 hours ago	Up 22 hours	0.0.0.0:8
R version 3.6.3 (2020-02-29) "Holding the Windsock" Copyright (C) 2020 The R Foundation for Statistical Computing	bdb15af01baa nginx lucid ardinghelli	"/docker-entrypoint"	22 hours ago	Up 22 hours	80/tcp
Platform: x86_64-pc-linux-gnu (64-bit)	93f7f3273920 nginx 0/tcp elated wright	"/docker-entrypoint"	22 hours ago	Up 22 hours	0.0.0.0:8
R is free software and comes with ABSOLUTELY NO WARRANTY. You are welcome to redistribute it under certain conditions.	b96d29b99167 nginx 0/tcp clever leavitt	"/docker-entrypoint"	22 hours ago	Up 22 hours	0.0.0.0:8
are welcome to redistribute it under certain conditions.  'license()' or 'licence()' for distribution details.	ba237891213d fedora inspiring austin	"/bin/bash"	22 hours ago	Up 22 hours	
R is a collaborative project with many contributors.	64c74c50cc8c fedora kind minsky	"/bin/bash"	22 hours ago	Up 22 hours	
Type 'contributors()' for more information and 'citation()' on how to cite R or R packages in publications.	29cd732bd5e8 fedora boring hodgkin	"/bin/bash"	22 hours ago	Up 22 hours	
Type 'demo()' for some demos, 'help()' for on-line help, or	5e6d4d17a8ae fedora gallant hodgkin	"/bin/bash"	22 hours ago	Up 22 hours	
'help.start()' for an HTML browser interface to help. Type 'q()' to quit R.	31320a3dc124 fedora admiring jang	"/bin/bash"	22 hours ago	Up 22 hours	
>	x79056166@hadoop-master:~\$				

Figura 5: Comprobando ejecución.

## 1.3.2. En Azure

Tal y como está el archivo Dockerfile, si se desplegara en Azure se crearía una "container instance" que cargaría la imagen ejecutando el script, y se cerraría inmediatamente. Para poder acceder al contenedor antes de que se cierre, es necesario lanzar algún servicio que se mantenga en ejecutando/espera. Una opción sería desplegar una app web como Django o Flask, pero por simplicidad lanzaremos el comando indicado en https://docs.microsoft.com/en-us/azure/container-instances/container-instances-troubleshooting#issues-during-container-group-runtime

```
1 FROM <u>ubuntu</u>
2 LABEL author="Ignacio Vellido Expósito"
3 # ENV http_proxy http://stargate.ugr.es:3128
4
5 # To don't get asked about geographic location (disable dpkg interactivity)
6 ENV DEBIAN_FRONTEND=noninteractive
7
8 # Install R and tidyverse
9 RUN apt-get update && \
10 apt-get install -y r-base \
11 r-cran-tidyverse
12
13 RUN R -e "install.packages(c('caret','RSNNS','frbs','FSinR','forecast'), \
14 dependencies=TRUE, repos='http://cran.rstudio.com/')"
15
16 # Launch test script
17 COPY testDocker.R /home/testDocker.R
18 RUN cd /home && \
19 Rscript /home/testDocker.R > /home/testOutput.txt
20
21 # For Azure (to keep container alive)
22 CMD [ "tail", "-f", "/dev/null" ]
```

Figura 6: Dockerfile modificado.

Para hacer el despliegue, primeramente se crea un repositorio privado en Docker Hub, y se le cambia el nombre a la imagen de hadoop para adaptarla al repositorio.

```
x79056166@hadoop-master:~$ docker login
Login with your Docker ID to push and pull images from Docker Hub. If you don't have a Docker ID,
ub.docker.com to create one.
Username: ignaciove
Password:
WARNING! Your password will be stored unencrypted in /home/x79056166/.docker/config.json.
Configure a credential helper to remove this warning. See
https://docs.docker.com/engine/reference/commandline/login/#credentials-store

Login Succeeded
x79056166@hadoop-master:~$ docker push ignaciove/big_data_i:cdr
The push refers to repository [docker.io/ignaciove/big_data_i]
19c81e3a4cbd: Pushed
6cdcaaf11e6c: Pushed
6cdcaaf11e6c: Pushed
468c259c5bf8: Pushed
8a63c95bf6c7: Pushed
8a63c95bf6c7: Pushed
9a63c984dbbe9: Mounted from danijorq/sgbd
9a69f84dbbe9: Mounted from danijorq/sgbd
bacd3af13903: Mounted from danijorq/sgbd
cdr: digest: sha256:193718fa7fd7520e7ce6ba2fa8c79c09283a9693948dea4b293be9ac79d9821a size: 1785
```

Figura 7: Subiendo imagen al repositorio.



Figura 8: Imagen en Docker Hub.




Figura 9: Desplegando el contenedor en Azure.




Figura 10: Desplegando el contenedor en Azure.




Figura 11: Contenedor en ejecución.

# 1.4. Evaluación

Para evaluar el contenedor en ambas plataformas se ha comprobado la salida del scripts. En este script se cargan todas las bibliotecas adicionales instaladas y se aplican operaciones con algunas de ellas.

Figura 12: Script de prueba.

# 2. Contenedor para actividades de ciencia de datos basado en Python

# 2.1. Descripción

Contenedor partiendo de una imagen base de Ubuntu al que se le añade Python con distintos paquetes de ciencia de datos, concretamente:

- pandas, numpy, scikit-learn
- seaborn, scipy
- matplotlib, xlrd

# 2.2. Archivo Dockerfile

Para la construcción del archivo Dockerfile se parte de las recomendaciones de https://hub.docker.com/\_/python y se adapta para una instalación base de Ubuntu.

```
LABEL author="Ignacio Vellido Expósito"
ENV http_proxy http://stargate.ugr.es:3128
# To don't get asked about geographic location (disable dpkg interactivity)
ENV DEBIAN_FRONTEND=noninteractive
RUN apt-get update && \
    apt-get install -y python3 python3-pip
WORKDIR /usr/src/app
COPY requirements.txt ./
RUN pip3 install --upgrade pip && \
   pip3 install --no-cache-dir -r requirements.txt && \
    rm requirements.txt
COPY data /home/data
COPY testDocker.py /home/testDocker.py
RUN cd /home && \
    python3 /home/testDocker.py > /home/testOutput.txt
CMD [ "python3" ]
```

Figura 13

```
cdpython > \(\begin{array}{c}\text{ requirements.txt}\\ 1 & pandas\\ 2 & scikit-learn\\ 3 & seaborn\\ 4 & scipy\\ 5 & numpy\\ 6 & matplotlib\\ 7 & xlrd\end{array}\)
```

Figura 14: Archivo con los paquetes a instalar.

# 2.3. Proceso de construcción

#### 2.3.1. En hadoop.ugr.es

```
**O : 79056166@hadoop-master -/dpython
Downloading pip-20.3.3-py2.py3-none-any.whl (1.5 MB)
Installing collected packages: pip
Attempting uninstalling pip at /usr/lib/python3/dist-packages, outside environment /usr
Can't uninstall' pip', No files were found to uninstall.
Successfully installed pip-20.3.3
Collecting pandas-12.1-cp38-cp38-manylinux1_x86_64.whl (9.7 MB)
Collecting scikt-learn
Downloading pandas-12.1-cp38-cp38-manylinux2010_x86_64.whl (24.9 MB)
Collecting scikt-learn-0.24.1-cp38-cp38-manylinux2010_x86_64.whl (24.9 MB)
Collecting scikt-learn-0.24.1-cp38-cp38-manylinux2010_x86_64.whl (27.2 MB)
Collecting scipy
Downloading scipy-1.6.0-cp38-cp38-manylinux2010_x86_64.whl (14.9 MB)
Collecting inumpy
Downloading scipy-1.6.0-cp38-cp38-manylinux2010_x86_64.whl (14.9 MB)
Collecting inumpy
Downloading numpy 1.19.5-cp38-cp38-manylinux2010_x86_64.whl (14.9 MB)
Collecting inumpy
Downloading x1dr-2.0.1-py2.py3-none-any.whl (96 kB)
Collecting python-dateutil>-2.7.3
Downloading x1dr-2.0.1-py2.py3-none-any.whl (27 kB)
Collecting python-dateutil>-2.7.3
Downloading python dateutil>-2.7.3
Downloading python dateutil>-2.7.3
Downloading python-dateutil>-2.7.3
Downloading python-dateutil
-2.7.0
Dow
```

Figura 15: Construcción de la imagen.

```
x79056166@hadoop-master:~/cdpython$ docker run -i -t x79056166/cdpython /bin/bash
root@def12a2da856:/usr/src/app# ls /home/
data figure1.png figure2.png figure3.png figure4.png figure5.png figure6.png testDocker.py testOutput.txt
root@def12a2da856:/usr/src/app#
```

Figura 16: Lanzando la imagen.

```
root@def12a2da856:/usr/src/app# cat /home/testOutput.txt
Datos sin normalizar:
                                         Median
                                                            Tendency
                                                                            NSP
      120.0
             120.0
                    0.0
                         0.0
                              0.0
                                          121.0
                                                                  1.0
                                                                      0.0
                                                                            2.0
                                                      73.0
                    4.0
                                          140.0
                                                      12.0
                                                                  0.0
                                                                      0.0
                                                                            1.0
      132.0
             132.0
                         0.0
                              4.0
                               5.0
     133.0
             133.0
                    2.0
                         0.0
                                          138.0
                                                      13.0
                                                                 0.0
                                                                      0.0
                                                                            1.0
                                          137.0
      134.0
             134.0
                    2.0
                                                      13.0
                                                                 1.0
                                                                      0.0
                                                                            1.0
                         0.0
                               6.0
                    4.0
      132.0
             132.0
                         0.0
                               5.0
                                           138.0
                                                      11.0
                                                                 1.0
                                                                      0.0
                                                                            1.0
                                                       2.0
      140.0
             140.0
                    0.0
                         0.0
                               6.0
                                           152.0
                                                                 0.0
                                                                      1.0
      140.0
             140.0
                    1.0
                         0.0
                                          151.0
                                                                      1.0
                                                                            2.0
2123
                               9.0
                                                       3.0
                                                                 1.0
             140.0
                                                                            2.0
2124
     140.0
                    1.0
                         0.0
                               7.0
                                          152.0
                                                       4.0
                                                                 1.0
                                                                      1.0
             140.0
142.0
     140.0
                    1.0
                              9.0
                                          151.0
                                                                      1.0
                                                                            2.0
2125
                         0.0
                                                                 1.0
                                                       4.0
     142.0
                    1.0
                         1.0
                                          145.0
                                                                 0.0
                                                                      0.0
                                                                            1.0
2126
                               5.0
                                                       1.0
[2126 rows x 25 columns]
Datos normalizados:
                                                                   Tendency
1.0
               LB
                     AC
                                          Mean
                                                Median
                                                         Variance
             120.0
                         0.0
                                                             73.0
12.0
                                                  121.0
      120.0
                    0.0
                               0.0
                                         137.0
                                                                              0.0
                                                                         0.0
                                                                              0.0
             132.0
                    4.0
                         0.0
                               4.0
                                         136.0
                                                  140.0
      132.0
                    2.0
                                         135.0
                              5.0
                                                  138.0
     133.0
             133.0
                         0.0
                                                             13.0
                                                                         0.0
                                                                             0.0
      134.0
             134.0
                         0.0
                               6.0
                                          134.0
                                                  137.0
                                                              13.0
                                                                         1.0
      132.0
             132.0
                    4.0
                         0.0
                               5.0
                                          136.0
                                                  138.0
                                                             11.0
                                                                         1.0
                                                                              0.0
                                                              2.0
                                                  152.0
2122
     140.0
             140.0
                    0.0
                         0.0
                               6.0
                                          150.0
                                                                         0.0
                                                                              1.0
                    1.0
                                         148.0
                                                  151.0
                                                                        1.0
     140.0
             140.0
                         0.0
                              9.0
                                                              3.0
2123
                                                                             1.0
     140.0
             140.0
                    1.0
                         0.0
                               7.0
                                         148.0
                                                              4.0
                                                                              1.0
2124
                                                  152.0
                                                                         1.0
2125
     140.0
             140.0
                    1.0
                         0.0
                              9.0
                                         147.0
                                                  151.0
                                                              4.0
                                                                         1.0
                                                                              1.0
             142.0
2126
     142.0
                    1.0
                         1.0
                               5.0
                                          143.0
                                                  145.0
                                                              1.0
                                                                         0.0
                                                                              0.0
[2126 rows x 24 columns]
              LBE
                                          Tendency
      2126.000000
                    2126.000000
                                       2126.000000
                                                     2126.000000
count
        133.303857
                     133.303857
                                          0.320320
                                                        0.033866
mean
                       9.840844
std
         9.840844
                                          0.610829
                                                        0.180928
min
        106.000000
                     106.000000
                                          -1.000000
                                                        0.000000
25%
        126.000000
                     126.000000
                                          0.000000
                                                        0.000000
50%
        133.000000
                     133.000000
                                          0.000000
                                                        0.000000
75%
        140.000000
                     140.000000
                                          1.000000
                                                        0.000000
        160.000000
                     160.000000
                                          1.000000
                                                        1.000000
nax
[8 rows x 24 columns]
            counts
                       freqs
ategories
              1655
                    0.778457
               295
                    0.138758
               176 0.082785
Clasificando con SVM
Mejores hiperparámetros del modelo:
 'C': 100000.0, 'gamma': 0.001, 'kernel': 'poly'}
Mejor score obtenido:
0.8505882352941176
Resultados de la predicción sobre test:
              precision
                            recall f1-score
                                                support
     Normal
                   0.87
                              0.96
                                        0.91
                                                    325
                   0.86
     Suspect
                              0.71
                                        0.78
                                                     42
                   0.53
                                                     59
 Pathologic
                              0.29
                                        0.37
```

Figura 17: Contenido de la imagen.



Figura 18: Comprobando ejecución.

#### 2.3.2. En Azure

Los pasos para desplegar la imagen en Azure son los mismos que con el contenedor de R. Es necesario modificar el Dockerfile y subirlo al repositorio, e indicarle a Azure dónde encontrar la imagen.

```
FROM ubuntu
LABEL author="Ignacio Vellido Expósito"
# ENV http_proxy http://stargate.ugr.es:3128
# To don't get asked about geographic location (disable dpkg interactivity)
ENV DEBIAN_FRONTEND=noninteractive
RUN apt-get update && \
    apt-get install -y python3 python3-pip
WORKDIR /usr/src/app
COPY requirements.txt ./
RUN pip3 install --upgrade pip && \
    pip3 install --no-cache-dir -r requirements.txt && \
    rm requirements.txt
COPY data /home/data
COPY testDocker.py /home/testDocker.py
RUN cd /home && \
    python3 /home/testDocker.py > /home/testOutput.txt
CMD [ "tail", "-f", "/dev/null" ]
```

Figura 19: Dockerfile desplegado en Azure.




Figura 20: Despliegue del contenedor en Azure.




Figura 21: Imagen del contenedor en ejecución.

#### 2.4. Evaluación

Para evaluar el correcto funcionamiento se lanza el siguiente script, que carga los paquetes instalados y realiza un aprendizaje sobre un conjunto de datos con SVM.

```
/usr/bin/env python3
   # Librerías
   import random
   import pandas as pd
   import numpy as np
   import matplotlib.pyplot as plt
   import seaborn as sns
   # Preprocesamiento
   from sklearn.preprocessing import Normalizer
   from sklearn.model_selection import train_test_split
   from sklearn.decomposition import PCA
   from sklearn.svm import SVC
20
   from sklearn.model_selection import GridSearchCV
   from sklearn.model_selection import KFold
   # Evaluación
   from sklearn.metrics import classification report, \
                     confusion_matrix, \
                     plot_confusion_matrix
   random.seed(9999)
   # Cargamos los datos (sheet Raw Data nos es más cómodo que Data)
   data = pd.read_excel("data/CTG.xls", "Raw Data")
   data = data[:-3]
   data = data[1:]
   # Eliminamos las columnas que no contienen información relevante para la
```

Figura 22: Parte del script de prueba.

# 3. Contenedor con SGDB MySQL

# 3.1. Descripción

Contenedor docker partiendo de una instalación base de MySQL, permitiendo consultas desde el exterior del contenedor.

# 3.2. Archivo Dockerfile

```
FROM mysql
LABEL author="Ignacio Vellido Expósito"

# Upload test DB
ENV MYSQL_DATABASE testDB
ENV MYSQL_USER testUser
ENV MYSQL_PASSWORD testPass

# All scripts in docker-entrypoint-initdb.d/ are automatically
# executed during container startup

COPY testDocker.sql /docker-entrypoint-initdb.d/
```

Figura 23

Creamos en el archivo Dockerfile un usuario para realizar las pruebas e incluímos una base de datos a partir de un script.

# 3.3. Proceso de construcción

### 3.3.1. En local

```
| Company | Comp
```

Figura 24: Construcción del contenedor y ejecución desde fuera de él.

Figura 25: Entrando como usuario root.

#### 3.3.2. En Azure

Una vez más para desplegar el contenedor en Azure subimos la imágen al repositorio y creamos una nueva "container instance".

Para este contenedor es necesario indicarle a Azure el puerto exportado en la imagen, y modificar el Dockerfile para incluir la contraseña del root (puesto que no se le puede indicar a Azure en el momento de ejecución).

```
FROM mysql
LABEL author="Ignacio Vellido Expósito"

# Upload test DB
ENV MYSQL_DATABASE testDB
ENV MYSQL_USER testUser
ENV MYSQL_PASSWORD testPass
ENV MYSQL_ROOT_PASSWORD root

# All scripts in docker-entrypoint-initdb.d/ are automatically
# executed during container startup

COPY testDocker.sql /docker-entrypoint-initdb.d/
```

Figura 26: Dockerfile modificado.




Figura 27: Creando contenedor.




Figura 28: Indicando el puerto exportado.




Figura 29: Accediendo a través de la IP pública.




Figura 30: Logs del contenedor.

# 3.4. Evaluación

La evaluación únicamente se basa en poder acceder al usuario creado en el Dockerfile, corroborando la correcta inclusión de la base de datos de prueba.

Figura 31: Fragmento de la base de datos insertada.