

UNIVERSIDAD DE GRANADA

BIG DATA I MÁSTER CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES

CLOUD COMPUTING Y BIG DATA

PRÁCTICA SOBRE CONTENEDORES

Autor

Ignacio Vellido Expósito ignaciove@correo.ugr.es





ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

 $Curso\ 2020\hbox{-}2021$

Índice

1.	Con	tenedor con SGDB MySQL	2
	1.1.	Descripción	2
	1.2.	Archivo Dockerfile	2
	1.3.	Proceso de construcción	2
		1.3.1. En hadoop.ugr.es	2
		1.3.2. En Azure	2
	1.4.	Evaluación	2
2.	Con	ntenedor para actividades de ciencia de datos basado en Python	3
	2.1.	Descripción	3
	2.2.	Archivo Dockerfile	3
	2.3.	Proceso de construcción	5
		2.3.1. En hadoop.ugr.es	5
		2.3.2. En Azure	7
	2.4.	Evaluación	7
3.	Contenedor para actividades de ciencia de datos basado en R		9
	3.1.	Descripción	9
	3.2.	Archivo Dockerfile	9
	3.3.	Proceso de construcción	10
		3.3.1. En hadoop.ugr.es	10
		3.3.2. En Azure	11
	3.4.	Evaluación	14
Referencias			15

1. Contenedor con SGDB MySQL

1.1. Descripción

Contendor docker partiendo de una instalación base de MariaDB

1.2. Archivo Dockerfile

1.3. Proceso de construcción

1.3.1. En hadoop.ugr.es

1.3.2. En Azure

1.4. Evaluación

Para la evaluación del contenedor se añade una pequeña base de datos sobre la que se realizan las siguientes pruebas.

2. Contenedor para actividades de ciencia de datos basado en Python

2.1. Descripción

Contenedor partiendo de una imagen base de Ubuntu al que se le añade Python con distintos paquetes de ciencia de datos, concretamente:

- pandas
- scikit-learn
- seaborn
- scipy
- numpy
- matplotlib
- xlrd

2.2. Archivo Dockerfile

```
1 FROM <u>ubuntu</u>
2 LABEL author="Ignacio Vellido Expósito"
3 ENV http_proxy http://stargate.ugr.es:3128
4
5 # To don't get asked about geographic location (disable dpkg interactivity)
6 ENV DEBIAN_FRONTEND=noninteractive
7
8 RUN apt-get update && \
9 apt-get install -y python3 python3-pip
10
11 WORKDIR /usr/src/app
12
13 COPY requirements.txt ./
14
15 RUN pip3 install --upgrade pip && \
16 pip3 install --no-cache-dir -r requirements.txt && \
17 rm requirements.txt
18
19 # Launch test script
10 COPY data /home/data
11 COPY data /home/data
12 COPY testDocker.py /home/testDocker.py
13 RUN cd /home && \
14 python3 /home/testDocker.py > /home/testOutput.txt
15 # Launch Python
16 CMD [ "python3" ]
```

Figura 1

Figura 2: Archivo con los paquetes a instalar

Para la construcción del archivo Dockerfile se parte de las recomendaciones de https://hub.docker.com/_/python y se adapta para una instalación base de Ubuntu.

2.3. Proceso de construcción

2.3.1. En hadoop.ugr.es

```
**Option Content of the Content of t
```

Figura 3: Construcción de la imagen

```
x79056166@hadoop-master:~/cdpython$ docker run -i -t x79056166/cdpython /bin/bash
root@def12a2da856:/usr/src/app# ls /home/
data figure1.png figure2.png figure3.png figure4.png figure5.png figure6.png testDocker.py testOutput.txt
root@def12a2da856:/usr/src/app#
```

Figura 4: Lanzando la imagen

```
root@def12a2da856:/usr/src/app# cat /home/testOutput.txt
Datos sin normalizar:
                                         Median
                                                            Tendency
                                                                            NSP
      120.0
             120.0
                    0.0
                         0.0
                              0.0
                                          121.0
                                                                  1.0
                                                                      0.0
                                                                            2.0
                                                      73.0
                    4.0
                                          140.0
                                                      12.0
                                                                  0.0
                                                                            1.0
     132.0
             132.0
                         0.0
                              4.0
                                                                      0.0
                               5.0
     133.0
             133.0
                    2.0
                         0.0
                                          138.0
                                                      13.0
                                                                 0.0
                                                                      0.0
                                                                            1.0
                                          137.0
      134.0
             134.0
                    2.0
                         0.0
                                                      13.0
                                                                 1.0
                                                                      0.0
                                                                            1.0
                               6.0
                    4.0
      132.0
             132.0
                         0.0
                               5.0
                                          138.0
                                                      11.0
                                                                 1.0
                                                                      0.0
                                                                            1.0
                                                       2.0
      140.0
             140.0
                    0.0
                         0.0
                               6.0
                                           152.0
                                                                 0.0
                                                                      1.0
      140.0
             140.0
                    1.0
                         0.0
                                          151.0
                                                                      1.0
                                                                            2.0
2123
                               9.0
                                                       3.0
                                                                 1.0
             140.0
                                                                            2.0
2124
     140.0
                    1.0
                         0.0
                               7.0
                                          152.0
                                                       4.0
                                                                 1.0
                                                                      1.0
             140.0
142.0
     140.0
                    1.0
                              9.0
                                          151.0
                                                                      1.0
                                                                            2.0
2125
                         0.0
                                                                 1.0
                                                       4.0
     142.0
                    1.0
                         1.0
                                          145.0
                                                                 0.0
                                                                      0.0
                                                                            1.0
2126
                               5.0
                                                       1.0
[2126 rows x 25 columns]
Datos normalizados:
                                                                   Tendency
1.0
               LB
                     AC
                                          Mean Median
                                                         Variance
             120.0
                         0.0
                                                             73.0
12.0
                                                 121.0
      120.0
                    0.0
                               0.0
                                         137.0
                                                                              0.0
                                                                         0.0
                                                                              0.0
             132.0
                    4.0
                         0.0
                               4.0
                                         136.0
                                                  140.0
      132.0
                                         135.0
                    2.0
                              5.0
                                                  138.0
     133.0
             133.0
                         0.0
                                                             13.0
                                                                         0.0
                                                                             0.0
                    2.0
      134.0
             134.0
                         0.0
                               6.0
                                         134.0
                                                  137.0
                                                             13.0
                                                                         1.0
                                                                              0.0
      132.0
             132.0
                    4.0
                         0.0
                               5.0
                                         136.0
                                                  138.0
                                                             11.0
                                                                         1.0
                                                                              0.0
                                                              2.0
                                                  152.0
2122
     140.0
             140.0
                    0.0
                         0.0
                               6.0
                                         150.0
                                                                         0.0
                                                                              1.0
                    1.0
                                         148.0
                                                  151.0
                                                                        1.0
     140.0
             140.0
                         0.0
                              9.0
                                                              3.0
2123
                                                                             1.0
     140.0
             140.0
                    1.0
                         0.0
                               7.0
                                         148.0
                                                              4.0
                                                                              1.0
2124
                                                  152.0
                                                                         1.0
2125
     140.0
             140.0
                    1.0
                         0.0
                              9.0
                                         147.0
                                                  151.0
                                                              4.0
                                                                         1.0
                                                                              1.0
             142.0
2126
     142.0
                    1.0
                         1.0
                               5.0
                                         143.0
                                                  145.0
                                                              1.0
                                                                         0.0
                                                                              0.0
[2126 rows x 24 columns]
                                          Tendency
      2126.000000
                    2126.000000
                                       2126.000000
                                                     2126.000000
count
        133.303857
                     133.303857
                                          0.320320
                                                        0.033866
mean
                       9.840844
std
         9.840844
                                          0.610829
                                                        0.180928
min
        106.000000
                     106.000000
                                          -1.000000
                                                        0.000000
25%
        126.000000
                     126.000000
                                          0.000000
                                                        0.000000
50%
        133.000000
                     133.000000
                                          0.000000
                                                        0.000000
75%
        140.000000
                     140.000000
                                          1.000000
                                                        0.000000
        160.000000
                     160.000000
                                          1.000000
                                                        1.000000
nax
[8 rows x 24 columns]
            counts
                       freqs
ategories
              1655
                    0.778457
               295
                    0.138758
               176 0.082785
Clasificando con SVM
Mejores hiperparámetros del modelo:
 'C': 100000.0, 'gamma': 0.001, 'kernel': 'poly'}
Mejor score obtenido:
0.8505882352941176
Resultados de la predicción sobre test:
              precision
                            recall f1-score
                                                support
     Normal
                   0.87
                              0.96
                                        0.91
                                                    325
                   0.86
    Suspect
                             0.71
                                        0.78
                                                     42
                   0.53
                                                     59
 Pathologic
                              0.29
                                        0.37
```

Figura 5: Contenido de la imagen



Figura 6: Comprobando ejecución

2.3.2. En Azure

2.4. Evaluación

Para evaluar el correcto funcionamiento se lanza el siguiente script, que carga los paquetes instaladas y realiza un aprendizaje sobre un conjunto de datos con SVM.

```
#! /usr/bin/env python3
   # Librerías
   import random
   import pandas as pd
   import numpy as np
   import matplotlib.pyplot as plt
   import seaborn as sns
   # Preprocesamiento
   from sklearn.preprocessing import Normalizer
   from sklearn.model_selection import train_test_split
   from sklearn.decomposition import PCA
20
   from sklearn.svm import SVC
   from sklearn.model_selection import GridSearchCV
   from sklearn.model_selection import KFold
   from sklearn.metrics import classification_report, \
                         confusion matrix, \
                         plot_confusion_matrix
   # Semilla con la que se han analizado los resultados
   random.seed(9999)
   # Cargamos los datos (sheet Raw Data nos es más cómodo que Data)
   data = pd.read_excel("data/CTG.xls", "Raw Data")
   data = data[:-3]
   # Eliminamos la primera fila que está vacía
   data = data[1:]
   # Eliminamos las columnas que no contienen información relevante para la
   removed_columns = ["FileName", "Date", "SegFile", "b", "e", "A", "B", "C", "D",
                   "AD", "DE", "LD", "FS", "SUSP", "CLASS"]
```

Figura 7: Script de prueba

3. Contenedor para actividades de ciencia de datos basado en R

3.1. Descripción

Contenedor partiendo de una imagen base de Ubuntu al que se le añade R con distintos paquetes de ciencia de datos, concretamente:

- tidyverse
- caret
- RSNNS
- frbs
- FSinR
- forecast

3.2. Archivo Dockerfile

```
1 FROM ubuntu
2 LABEL author="Ignacio Vellido Expósito"
3 ENV http_proxy http://stargate.ugr.es:3128
4
5 # To don't get asked about geographic location (disable dpkg interactivity)
6 ENV DEBIAN_FRONTEND=noninteractive
7
8 # Install R and tidyverse
9 RUN apt-get update && \
10 apt-get install -y r-base \
11 | r-cran-tidyverse
12
13 RUN R -e "install.packages(c('caret','RSNNS','frbs','FSinR','forecast'), \
14 dependencies=TRUE, repos='http://cran.rstudio.com/')"
15 |
16 # Launch test script
17 COPY testDocker.R /home/testDocker.R
18 RUN cd /home && \
19 Rscript /home/testDocker.R > /home/testOutput.txt
20 |
21 # Launch R
22 CMD [ "R" ]
```

Figura 8

El paquete "tidyverse" es necesario instalarlo a través de apt-get para evitar errores. Se incluye el proceso de testeo dentro del dockerfile para agilizar las pruebas, y se concluye indicando el comando por defecto de ejecución del script.

3.3. Proceso de construcción

3.3.1. En hadoop.ugr.es

```
Consideration and activation docker to Docker deason 1.68888

Step 19 : RRM ubunts

- 7464:750-252

- 19 : RRM ubunts

- 19 : RRM ref ubunts

- 19 : RRM ref ubunts

- 19 : RRM ref ubunts

- 19 : RRM RRM ref ubunts

- 19 : RRM RRM ref ubunts

- 19 : RRM ref ubunts

- 10 : RRM ref u
```

Figura 9: Construcción de la imagen

```
x79056166@hadoop-master:~/cdr$ docker run -i -t x79056166/cdr
R version 3.6.3 (2020-02-29) -- "Holding the Windsock"
Copyright (C) 2020 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)
R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.
Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.
```

Figura 10: Lanzando la imagen

```
master:~/cdr$ docker run -i -t x79056166/cdr /bin/bash
root@5ace4be08114:/# ls /home/
Rplots.pdf testDocker.R testG
                                gplot.png testOutput.txt
root@5ace4be08114:/# cat /home/testOutput.txt
c-Nearest Neighbors
150 samples
 4 predictor
 2 classes: 'negative', 'positive'
Pre-processing: centered (4), scaled (4)
Resampling: Cross-Validated (5 fold, repeated 3 times)
Summary of sample sizes: 120, 120, 120, 120, 120, 120, ...
Resampling results across tuning parameters:
                 Sens
                            Spec
     0.9400000
                 0.9600000
                            0.9200000
     0.9701667
                 0.9666667
                            0.9266667
     0.9895000
                 0.9766667
                            0.9400000
                 0.9766667
     0.9923333
                            0.9066667
                 0.9800000
     0.9918333
                            0.9066667
     0.9908333
                 0.9733333
                            0.9133333
ROC was used to select the optimal model using the largest value.
The final value used for the model was k = 7.
```

Figura 11: Contenido de la imagen



Figura 12: Comprobando ejecución

3.3.2. En Azure

Primeramente se crea un repositorio privado en Docker Hub, y se le cambia el nombre a la imagen de hadoop para adaptarla al repositorio

```
x79056166@hadoop-master:~$ docker login
Login with your Docker ID to push and pull images from Docker Hub. If you don't have a Docker ID,
ub.docker.com to create one.
Username: ignaciove
Password:
WARNING! Your password will be stored unencrypted in /home/x79056166/.docker/config.json.
Configure a credential helper to remove this warning. See
https://docs.docker.com/engine/reference/commandline/login/#credentials-store

Login Succeeded
x79056166@hadoop-master:~$ docker push ignaciove/big_data_i:cdr
The push refers to repository [docker.io/ignaciove/big_data_i]
19c81e3a4cbd: Pushed
6cdcaaf11e6c: Pushed
6cdcaaf11e6c: Pushed
6d8c259c5bf8: Pushed
9a63c95bf6c7: Pushed
66253634dc78: Mounted from danijorq/sgbd
9069f84dbbe9: Mounted from danijorq/sgbd
bacd3af13903: Mounted from danijorq/sgbd
cdr: digest: sha256:193718fa7fd7520e7ce6ba2fa8c79c09283a9693948dea4b293be9ac79d9821a size: 1785
```

Figura 13: Subiendo imagen al repositorio



Figura 14: Imagen en Docker Hub




Figura 15: Desplegando el contenedor en Azure




Figura 16: Desplegando el contenedor en Azure

3.4. Evaluación

Para evaluar se ha desplegado el contenedor en las diferentes plataformas y comprobado la salida del scripts. En este se cargan todas las bibliotecas adicionales instaladas y se aplican operaciones con algunas de ellas.

```
Test libraries
library(RSNNS)
library(FSinR)
library(caret)
# Test ggplot (and tidyverse)
ggplot(iris, aes(x=Sepal.Length, y=Petal.Length))
ggsave("testGgplot.png")
learn_model <-function(dataset, ctrl, message){</pre>
                   trControl = ctrl, preProcess = c("center", "scale"), metric="ROC",
                   tuneGrid = expand.grid(k = c(1,3,5,7,9,11)))
  model.cm <- caret::confusionMatrix(model.pred, dataset$Class,positive = "positive")</pre>
  model.probs <- predict(model.fit,newdata = dataset, type="prob")</pre>
  return(model.fit)
df$Class <- ifelse(df$Species == "virginica", "positive", "negative") %>% as.factor()
df$Species <- NULL
ctrl <- trainControl(method="repeatedcv",number=5,repeats = 3,</pre>
model.raw <- learn_model(df, ctrl, "RAW ")</pre>
print(model.raw)
```

Figura 17: Script de prueba

Referencias